


14.3.6. K平均クラスタリング

K平均法 (k-means) とは、最もよく利用される繰り返し降下クラスタリング法の1つ。

1. ランダムにクラスタの中心を選択(初期化)
2. 変数をユークリッド距離で最も近いクラスタに割り当て
3. 各クラスタの変数からクラスタの中心を再選択
4. クラスタの中心が変わらなくなるまで2~3を繰り返す

K平均法の例

左から、**初期中心**(1週目の2まで)、**初期分割**(1週目の3まで)、2週実行後、**20週実行後**の際のk平均法によるクラスタリングの様子を示す。



K平均法の公式

非類似度として、**2乗ユークリッド距離**が使われる。

$$d(x_i, x_{i'}) = \|x_i - x_{i'}\|^2$$

観測 i をクラス k に割り当てるために**符号化器** $C(i)$ が使われる。

クラス内分散は、平均ベクトル $\bar{x}_k$ と $N_k = \sum_{i=1}^N I(C(i) = k)$ より、

$$W(C) = \sum_{k=1}^K N_k \sum_{C(i)=k} \|x_i - \bar{x}_k\|^2$$

観測のあらゆる集合 S で(14.32)が成り立つため、

$$\bar{x}_S = \underset{m}{\operatorname{argmin}} \sum_{i \in S} \|x_i - m\|^2$$

目的を達成する符号化器を求める**繰り返し降下アルゴリズム**が、

$$C^* = \underset{C}{\operatorname{min}} \sum_{k=1}^K N_k \sum_{C(i)=k} \|x_i - \bar{x}_k\|^2$$

C^* を算出する際には、以下の**最適化問題**を扱う。

$$\underset{C, \{m_k\}_1^K}{\operatorname{min}} \sum_{k=1}^K M_k \sum_{C(i)=k} \|x_i - \bar{m}_k\|^2$$

K平均法のメリット

1. 計算が容易
2. **大規模なデータセット**でも利用可能

K平均法のデメリット

1. **球状**以外のクラスタは正しく捉えにくい
2. クラスタ数 k を決める必要
3. **外れ値**の影響を受けやすい
4. 初期クラスタ中心により**結果が変動**
→ 準最適な極所解

14.3.7. 混合ガウス

K平均法と**混合ガウス分布**を推定するための**EMアルゴリズム**が関連している。

- 混合ガウス分布(GMM) ... 複数の正規分布(ガウス分布)の組み合わせで、データ全体の確率分散を表現する統計モデル
- EMアルゴリズム ... 確率モデルのパラメータを**最尤推定**する手法の1つ

EMアルゴリズムは、**Eステップ**と**Mステップ**の繰り返しであり、

1. Eステップで観測不可能な潜在変数の**事後確率**を求める (= モデルの尤度の期待値)
2. Mステップで観測不可能な潜在変数の事後確率を最大化する**パラメータ**を求める

これが、k平均法のクラスタへの割り当て~クラスタの中心の再選択に似ている。

14.3.9. ベクトル量子化

ベクトル量子化(VQ) とは、ベクトル内の一部をブロックに分割する手法である。分割したブロック内で**コードワード**(最も近い中心)で近似し、1つの値にする。復号には、中心の集合である**コードブック**を利用する。


使い道としては、

1. データ圧縮
2. **次元圧縮**
3. 特徴量エンジニアリング

ベクトル量子化の例

左側の元画像をベクトル量子化した結果を**中央(K=200)**と**右側(K=4)**に示す。

- 中央は、多少の画質の劣化で**容量は0.24倍**程度に収まっている
- 右側は、かなりの画質の劣化があるが**容量は0.0625倍**まで抑えられている



14.3.10. Kメドイドクラスタリング

Kメドイド法とは、K平均法同様に非階層的なクラスタリングアルゴリズムである。

1. **任意の非類似度** D で、クラスタの**中心とするデータ点**を選択

$$\text{クラスタ中心集合 } i_k^* = \underset{\{i: C(i)=k\}}{\operatorname{argmin}} \sum_{C(i')=k} D(x_i, x_{i'})$$

2. 各クラスタの中心のデータ点から、各変数をクラスタに再割り当て

$$\text{クラスタ割り当て } C(i) = \underset{i \leq k \leq K}{\operatorname{argmin}} D(x_i, m_k)$$


3. 割り当ての変更がなくなるまで、1~2を繰り返す

Kメドイド法の例

右の図は、左の表である**政治科学調査により得られた各国の非類似度**を元にKメドイド法によりクラスタリングしたものである。 $(k = 3)$

距離のみが与えられているため、K平均法は使えない。

	BEL	BRA	CHI	CUB	EGY	FRA	IND	ISR	USA	USS	YUG
BRA	5.58										
CHI	7.00	6.50									
CUB	7.08	7.00	3.83								
EGY	4.83	5.08	8.17	5.83							
FRA	2.17	5.75	6.67	6.92	4.92						
IND	6.42	5.00	5.58	6.00	4.67	6.42					
ISR	3.42	5.50	6.42	6.42	5.00	3.92	6.17				
USA	2.50	4.92	6.25	7.33	4.50	2.25	6.33	2.75			
USS	6.08	6.67	4.25	2.67	6.00	6.17	6.17	6.92	6.17		
YUG	5.25	6.83	4.50	3.75	5.75	5.42	6.08	5.83	6.67	3.67	
ZAI	4.75	3.00	6.08	6.67	5.00	5.58	4.83	6.17	5.67	6.50	6.92



Kメドイド法のメリット

1. **外れ値**の影響を受けにくい
2. **任意の非類似度**が使える (マンハッタン距離(L1)、ユークリッド距離(L2)等)
3. 解釈性

Kメドイド法のデメリット

1. **計算量の多さ** (Kメドイド法 >> K平均法)
2. 初期クラスタ中心により**結果が変動**

14.3.11. 実用上の問題

K平均法・Kメドイド法は**クラスタ数** K^* や**初期値**を決める必要がある。

初期値は、以下のどちらかがあれば良い。

1. 中心 $\{m_1, \dots, m_K\}$ や $\{i_1, \dots, i_K\}$ の**初期集合**
2. **初期符号器** $C(i)$

通常は中心の初期集合の方が便利

初期化の手法としては、単純な**乱数**~**前浮き漸次的割り当て**まで多岐にわたる。

クラスタ数 K^* の選択は、**目的に依存する**。

特に、クラスタ分析により**自然なグループに分離できているか**を確認める際には、データから**クラスタ数を推定**する必要がある。


この推定は、**経験則**や**直感**に基づく準最適解を導く手法が多い。

14.3.12. 階層的クラスタリング

階層的クラスタリングは、K平均法やKメドイド法と比べて以下の1つの特徴がある。

1. **初期値**が存在しない
2. 階層的なクラスタが作成可能である
 - 2.1. 最も下の階層では、各クラスタは**1つの観測**のみ
 - 2.2. 最も上の階層では、**全観測を含む1つのクラスタ**のみ
3. **凝集型(ボトムアップ)** と **分割型(トップダウン)** の2種類がある
4. 再帰的な2つずつの分割や凝縮は**根付き二分木**で表現可 (**デンドログラム**)

階層的クラスタリングの例



左図は、ヒト腫瘍マイクロアレイデータに、**群平均凝集型階層的クラスタリング**を適用して得られた**デンドログラム**である。

デンドログラムは**視覚的な要約**として有用で、以下のような特徴がある。

1. 上位の階層で統合されたクラスタは**自然なクラスタ**の候補
2. **階層的手法**や**わずかなデータの相違**により、異なるデンドログラムが得られる

デンドログラムにより生成された階層構造が、どれだけデータを表現できているか、**共表形相関係数**で判断できる。

これは、

- $N(N - 1)/2$ 個の**観測間非類似度** $d_{ii'}$
- **共表形非類似度** $C_{ii'} \leq \max(C_{ik}, C_{i'k})$ (任意の3つの観測点 i, i', k)

の相関係数である。

凝縮型クラスタリング

個々のデータ点を**クラスタと見なし**、クラスタが1つになるまで結合させていく方式
使用頻度が**高い**

1. 全てのクラスタで**対称行列**を作る
2. **最も距離が大きいクラスタ**を最小にするようにクラスタを結合
3. 対称行列を作り直す
4. クラスタが1つになるまで、2~3を繰り返す

凝縮型クラスタリングでは、**クラスタ間の距離の違い**で以下の3つが良く使われる。

1. **単連結** ... グループの非類似度に**最短距離法**を使う

$$d_{SL}(G, H) = \min_{\substack{i \in G \\ i' \in H}} d_{ii'}$$


2. **完全連結** ... グループの非類似度に**最長距離法**を使う

$$d_{CL}(G, H) = \max_{\substack{i \in G \\ i' \in H}} d_{ii'}$$

3. **群平均** ... **グループ間**の平均類似度を使う。

$$d_{GA}(G, H) = \frac{1}{N_G N_H} \sum_{i \in G} \sum_{i' \in H} d_{ii'}$$

前述の凝縮型クラスタリングの違いは以下の通り。左から群平均、完全連結、単連結の凝縮型階層的クラスタリングで得られたデンドログラムである。



分割型クラスタリング

全データのクラスタからデータ点が1つだけ含まれるクラスタまで分割を繰り返す方式
使用頻度が低い

k平均法や**kメドイド法**もこの分割型クラスタリングに含まれる

14.4. 自己組織化マップ

自己組織化マップ(SOM) は、K平均法の**制約付き版**と見なせ、以下の特徴がある。

1. 高次元データを2次元座標系に写像できる (**制約付き位相マップ**)
→ 視覚的な理解が可
2. 入力の近さをマップ上での近さで表現
→ **データ間の関係が失われない**


自己組織化マップの手順は以下の通り

1. 2次元格子上的の K 個の**プロトタイプ** m_j を初期化
2. 入力 x_i を1つ取り出し、**最も近い**プロトタイプ m_j を探す
3. 全てのプロトタイプ m_k を x_i の方へ近づける

$$m_k \leftarrow m_k + \alpha(x_i - m_k) \quad (14.46)$$

4. 2~3を全ての入力において行う

自己組織化マップの例



左図は、**SOM**による当てはめ結果である3次元データを**2次元表示**できている。重なっている線は、赤点が**対角の位置にプロット**されており、2次元平面上で距離の関係を保つために、**曲面が対角線上に折りたたまれて**繋がっているから。

自己組織化マップのメリット

1. 次元圧縮
2. データの**構造**や**類似性**の保持

自己組織化マップのデメリット

1. 明確なクラスタの**ラベル**が存在しない
2. **初期値**やデータの**順番**に依存
 - 実用上では、前述の手順を**複数回**行い、一巡毎にデータをシャッフルする

自己組織化マップの変数には、**学習率** α と**距離閾値** r がある。

- 学習率 α は**数千ステップ**かけて $1.0 \rightarrow 0.0$ の様に減少させる。
- 距離閾値 r も**数千ステップ**かけて $R \rightarrow 1$ の様に減少させる。

洗練された自己組織化マップでは、距離によってプロトタイプの更新則を変更する。
近傍関数 h 、座標 l_i を使って、

$$m_k \leftarrow m_k + \alpha h(\|l_j - l_k\|)(x_i - m_k) \quad (14.47)$$

また、バッチ版では重み w_k を使って、

$$m_j = \frac{\sum w_k x_k}{\sum w_k}$$

参考文献

[1] 【目で見てわかる】 k-meansクラスタリングの基本から限界まで #Python - Qiita
(参照:2025/06/20)

<https://qiita.com/ryo18/items/4a775aeec61de07d2548>

[2] ベクトル量子化 - 環境と品質のためのデータサイエンス (参照:2025/06/22)

<https://data-science.tokyo/ed/edj1-5-3-5-2.html>

[3] k-medoids法 | 今更聞けないIT用語集 | 株式会社APPSWINGBY (参照:2025/06/22)

<https://appswingby.com/k-medoids法-今更聞けないit用語集/>

[4] 機械学習：階層的クラスタリング 凝縮型階層的アルゴリズム |

Dean4rmEdinburgh (参照:2025/06/23)

https://note.com/dean_edinburgh/n/n402bfd92d380

[5] 5分で分かる自己組織化マップ | PPT (参照:2025/06/23)

<https://www.slideshare.net/slideshow/5-13781247/13781247#84>

[6] 自己組織化マップ(Self-Organizing Map, SOM)～非線形の可視化・見える化手法、
ただ過学習の危険性も高いので注意！～ | データ化学工学研究室(金子研究室)@明治大
学 理工学部 応用化学科 (参照:2025/06/23)

<https://datachemeng.com/selforganizingmap/>