

14.3.6. K平均クラスタリング

K平均法 (k-means) とは、最もよく利用される繰り返し降下クラスタリング法の1つ。

1. ランダムにクラスタの中心を選択(初期化)
2. 変数をユークリッド距離で最も近いクラスタに割り当て
3. 各クラスタの変数からクラスタの中心を再選択
4. クラスタの中心が変わらなくなるまで2~3を繰り返す

K平均法の例

K平均法の公式

非類似度として、**2乗ユークリッド距離**が使われる。

$$d(x_i, x_{i'}) = \|x_i - x_{i'}\|^2$$

観測 i をクラス k に割り当てるために**符号化器** $C(i)$ が使われる。

クラス内分散は、平均ベクトル $\bar{x}_k$ と $N_k = \sum_{i=1}^N I(C(i) = k)$ より、

$$W(C) = \sum_{k=1}^K N_k \sum_{C(i)=k} \|x_i - \bar{x}_k\|^2$$

観測のあらゆる集合 S で(14.32)が成り立つため、

$$\bar{x}_S = \underset{m}{\operatorname{argmin}} \sum_{i \in S} \|x_i - m\|^2$$

目的を達成する符号化器を求める**繰り返し降下アルゴリズム**が、

$$C^* = \underset{C}{\min} \sum_{k=1}^K N_k \sum_{C(i)=k} \|x_i - \bar{x}_k\|^2$$

C^* を算出する際には、以下の**最適化問題**を扱う。

$$\underset{C, \{m_k\}_1^K}{\min} \sum_{k=1}^K M_k \sum_{C(i)=k} \|x_i - \bar{m}_k\|^2$$

K平均法のメリット

1. 計算が容易
2. **大規模なデータセット**でも利用可能

K平均法のデメリット

1. **球状**以外のクラスタは正しく捉えにくい
2. クラスタ数 k を決める必要
3. **外れ値**の影響を受けやすい
4. 初期クラスタ中心により**結果が変動**
→ 準最適な極所解

14.3.7. 混合ガウス

K平均法と**混合ガウス分布**を推定するための**EMアルゴリズム**が関連している。

- 混合ガウス分布(GMM) ... 複数の正規分布(ガウス分布)の組み合わせで、データ全体の確率分散を表現する統計モデル
- EMアルゴリズム ... 確率モデルのパラメータを**最尤推定**する手法の1つ

EMアルゴリズムは、**Eステップ**と**Mステップ**の繰り返しであり、

1. Eステップで観測不可能な潜在変数の**事後確率**を求める (= モデルの尤度の期待値)
2. Mステップで観測不可能な潜在変数の事後確率を最大化する**パラメータ**を求める

これが、k平均法のクラスタへの割り当て~クラスタの中心の再選択に似ている。

14.3.9. ベクトル量子化

ベクトル量子化(VQ) とは、ベクトル内の一部をブロックに分割する手法である。分割したブロック内で**コードワード**(最も近い中心)で近似し、1つの値にする。復号には、中心の集合である**コードブック**を利用する。

使い道としては、

1. データ圧縮
2. **次元圧縮**
3. 特徴量エンジニアリング

ベクトル量子化の例

14.3.10. Kメドイドクラスタリング

Kメドイド法とは、K平均法同様に非階層的なクラスタリングアルゴリズムである。

1. **任意の非類似度** D で、クラスタの**中心とするデータ点**を選択

$$\text{クラスタ中心集合 } i_k^* = \underset{\{i: C(i)=k\}}{\operatorname{argmin}} \sum_{C(i')=k} D(x_i, x_{i'})$$

2. 各クラスタの中心のデータ点から、各変数をクラスタに再割り当て

$$\text{クラスタ割り当て } C(i) = \underset{i \leq k \leq K}{\operatorname{argmin}} D(x_i, m_k)$$

3. 割り当ての変更がなくなるまで、1~2を繰り返す

Kメドイド法の例

Kメドイド法のメリット

1. **外れ値**の影響を受けにくい
2. **任意の非類似度**が使える (マンハッタン距離(L1)、ユークリッド距離(L2)等)
3. 解釈性

Kメドイド法のデメリット

1. **計算量の多さ** (Kメドイド法 >> K平均法)
2. 初期クラスタ中心により**結果が変動**

14.3.11. 実用上の問題

K平均法・Kメドイド法は**クラスタ数** K^* や**初期値**を決める必要がある。

初期値は、以下のどちらかがあれば良い。

1. 中心 $\{m_1, \dots, m_K\}$ や $\{i_1, \dots, i_K\}$ の**初期集合**
2. **初期符号器** $C(i)$

通常は中心の初期集合の方が便利

初期化の手法としては、単純な**乱数**~**前浮き漸次的割り当て**まで多岐にわたる。

クラスタ数 K^* の選択は、**目的に依存する**。

特に、クラスタ分析により**自然なグループに分離できているか**を確認める際には、データから**クラスタ数を推定**する必要がある。

この推定は、**経験則**や**直感**に基づく準最適解を導く手法が多い。

14.3.12. 階層的クラスタリング

階層的クラスタリングは、K平均法やKメドイド法と比べて以下の1つの特徴がある。

1. **初期値**が存在しない
2. 階層的なクラスタが作成可能である
 - 2.1. 最も下の階層では、各クラスタは**1つの観測**のみ
 - 2.2. 最も上の階層では、**全観測を含む1つのクラスタ**のみ
3. **凝集型(ボトムアップ)** と **分割型(トップダウン)** の2種類がある
4. 再帰的な2つずつの分割や凝縮は**根付き二分木**で表現可 (**デンドログラム**)

階層的クラスタリングの例

デンドログラムは**視覚的な要約**として有用で、以下のような特徴がある。

1. 上位の階層で統合されたクラスタは**自然なクラスタ**の候補
2. **階層的手法**や**わずかなデータの相違**により、異なるデンドログラムが得られる

デンドログラムにより生成された階層構造が、どれだけデータを表現できているか、**共表形相関係数**で判断できる。

これは、

- $N(N - 1)/2$ 個の**観測間非類似度** $d_{ii'}$
- **共表形非類似度** $C_{ii'} \leq \max(C_{ik}, C_{i'k})$ (任意の3つの観測点 i, i', k)

の相関係数である。

凝縮型クラスタリング

個々のデータ点を**クラスタと見なし**、クラスタが1つになるまで結合させていく方式
使用頻度が**高い**

1. 全てのクラスタで**対称行列**を作る
2. **最も距離が大きいクラスタ**を最小にするようにクラスタを結合
3. 対称行列を作り直す
4. クラスタが1つになるまで、2~3を繰り返す

凝縮型クラスタリングでは、**クラスタ間の距離の違い**で以下の3つが良く使われる。

1. **単連結** ... グループの非類似度に**最短距離法**を使う

$$d_{SL}(G, H) = \min_{\substack{i \in G \\ i' \in H}} d_{ii'}$$

2. **完全連結** ... グループの非類似度に**最長距離法**を使う

$$d_{CL}(G, H) = \max_{\substack{i \in G \\ i' \in H}} d_{ii'}$$

3. **群平均** ... **グループ間**の平均類似度を使う。

$$d_{GA}(G, H) = \frac{1}{N_G N_H} \sum_{i \in G} \sum_{i' \in H} d_{ii'}$$

前述の凝縮型クラスタリングの違いは以下の通り

分割型クラスタリング

全データのクラスタからデータ点が1つだけ含まれるクラスタまで分割を繰り返す方式
使用頻度が低い

k平均法や**kメドイド法**もこの分割型クラスタリングに含まれる

14.4. 自己組織化マップ

自己組織化マップ(SOM) は、K平均法の**制約付き版**と見なせ、以下の特徴がある。

1. 高次元データを2次元座標系に写像できる (**制約付き位相マップ**)
→ 視覚的な理解が可
2. 入力の近さをマップ上での近さで表現
→ **データ間の関係が失われない**

自己組織化マップの手順は以下の通り

1. 2次元格子上的の K 個の**プロトタイプ** m_j を初期化
2. 入力 x_i を1つ取り出し、**最も近い**プロトタイプ m_j を探す
3. 全てのプロトタイプ m_k を x_i の方へ近づける

$$m_k \leftarrow m_k + \alpha(x_i - m_k) \quad (14.46)$$

4. 2~3を全ての入力において行う

自己組織化マップの例

自己組織化マップのメリット

1. 次元圧縮
2. データの**構造**や**類似性**の保持

自己組織化マップのデメリット

1. 明確なクラスタの**ラベル**が存在しない
2. **初期値**やデータの**順番**に依存
 - 実用上では、前述の手順を**複数回**行い、一巡毎にデータをシャッフルする

自己組織化マップの変数には、**学習率** α と**距離閾値** r がある。

- 学習率 α は**数千ステップ**かけて $1.0 \rightarrow 0.0$ の様に減少させる。
- 距離閾値 r も**数千ステップ**かけて $R \rightarrow 1$ の様に減少させる。

洗練された自己組織化マップでは、距離によってプロトタイプの更新則を変更する。
近傍関数 h 、座標 l_i を使って、

$$m_k \leftarrow m_k + \alpha h(\|l_j - l_k\|)(x_i - m_k) \quad (14.47)$$

また、バッチ版では重み w_k を使って、

$$m_j = \frac{\sum w_k x_k}{\sum w_k}$$

参考文献

[1] 【目で見てわかる】 k-meansクラスタリングの基本から限界まで #Python - Qiita
(参照:2025/06/20)

<https://qiita.com/ryo18/items/4a775aeec61de07d2548>

[2] ベクトル量子化 - 環境と品質のためのデータサイエンス (参照:2025/06/22)

<https://data-science.tokyo/ed/edj1-5-3-5-2.html>

[3] k-medoids法 | 今更聞けないIT用語集 | 株式会社APPSWINGBY (参照:2025/06/22)

<https://appswingby.com/k-medoids法-今更聞けないit用語集/>

[4] 機械学習：階層的クラスタリング 凝縮型階層的アルゴリズム |

Dean4rmEdinburgh (参照:2025/06/23)

https://note.com/dean_edinburgh/n/n402bfd92d380

[5] 5分で分かる自己組織化マップ | PPT (参照:2025/06/23)

<https://www.slideshare.net/slideshow/5-13781247/13781247#84>

[6] 自己組織化マップ(Self-Organizing Map, SOM)～非線形の可視化・見える化手法、
ただ過学習の危険性も高いので注意！～ | データ化学工学研究室(金子研究室)@明治大
学 理工学部 応用化学科 (参照:2025/06/23)

<https://atachemeng.com/selforganizingmap/>