

14.6.1. アーキタイプ分析(Archetypal analysis)

観測データをそのデータの**アーキタイプ(多次元データ内の極値)**の混合によって近似する計算手法 [1]

→ Kmeansに似ている

- 特徴抽出や次元削減に利用(データの外側の点を調べることで、**概形がわかる**)
→ 直感的に理解しやすい表現へ
- AAはデータの線形変換やスケーリングに対して不変 [2]

14.7.1 潜在変数と因子分析

特異値分解(SVD) $X = UDV^T$ は**潜在変数**で表せる。

$$\bullet S = \sqrt{N}U, A^T = DV^T / \sqrt{N}$$

導入した2つの変数を使い、 $X = SA^T$ と表せる。

U が直交しており、 X の列(= U の列)の平均が0と仮定すると、

1. S の列の平均は0、分散は1で無相関

→ SVDやPCAは**潜在変数モデルの推定値と見なせる**

2. **因子分析**とは、 X_p の相関構造をモデル化すること

→ 原因究明や仮説の検証に使われる [3]

$$X_p = a_{p1}S_1 + a_{p2}S_2 + \dots + a_{pp}S_p \quad (14.78)$$

識別性の問題は残っており、現代の統計では因子分解はあまり使われていない

14.7.2 独立成分分析(ICA)

ICAとは、複数の観測データ/信号から独立な成分を推定する技術である [4]

可能な限り**正規分布から遠ざかる**ような直交射影の列を探す

→ 白色化データにおいては、**独立な成分を探すこと**

そして、独立な成分につながる**回転**を探す

ICAでは、(14.78)とほぼ同じものを考えるが S_p が**無相関ではなく統計的に独立である**という仮定をおく。これにより、因子分解の**識別性の問題が解決できる**。 [5]

実用上では、**話者分離**などに活用される [6]

14.7.3 探索的射影追求

高次元→低次元の射影は**ほぼ正規分布**に従う。

よって、クラスタ等の構造は**非正規分布の射影に依存する**という考え。

$$Y_j = a_j^T X$$

14.8 多次元尺度構成法(MDS)

MDSは**入力変数の各要素毎の距離**を計算し、高次元から**低次元にマッピング**する手法

- MDSでは**距離(類似度)** d_{ij} が必要
- 自己組織化マップ(SOM)や主曲線・主曲面は**データ** x_i が必要

MDSでは、全ての要素毎の距離を明示的に保持しようとする

- SOMや主平面で起きていた、特徴空間では**離れた点も近接してマッピング**される現象を回避することができる

参考

- [1] https://en.wikipedia.org/wiki/Archetypal_analysis
- [2] <https://www.themoonlight.io/ja/review/a-survey-on-archetypal-analysis>
- [3] <https://data-science.tokyo/ed/edj1-2-4.html>
- [4] <https://ja.wikipedia.org/wiki/独立成分分析>
- [5] <https://qiita.com/Miyabi1456/items/3fdc5a1603269db197d5>
- [6] <https://data-science.tokyo/ed/edj1-2-4-2.html>